

La alternativa abierta para el mundo de la IA



Sergio Paniego Blanco (@sergiopaniego)

Machine Learning Engineer @ Hugging Face





IA abierta vs propietaria





VS



Desventajas de la IA cerrada

- 
- No tenemos control de los datos
 - No tenemos control sobre posibles actualizaciones
 - No podemos auditar ni entender el rendimiento
 - Capacidad limitada de personalización
 - ...
- 
- 



**“Not your weights, not
your brain!”**

Andrej Karpathy



La alternativa



El ecosistema de la IA abierta

- **Modelos abiertos**
 - Qwen, Gemma, Mistral, DeepSeek, Llama...
- **Datos abiertos**
 - Wikipedia, Human preference, ImageNet...
- **Proyectos de código abierto**
 -    **Transformers** 
- **Investigación abierta**
 - 

Quiénes son los jugadores?



	+ abiertas	+ cerradas
Gigantes tech	 Meta 	amazon  Apple  
Otros jugadores	     deepseek 	 AI

More details: [Hugging Face Heatmap](#)

Abierta vs Propietaria



	Abierta	Cerrada / Propietaria
Seguridad	Los modelos pueden alojarse localmente . Los datos permanecen en tu entorno	Los modelos no pueden alojarse localmente. Tus datos se envían fuera de tu entorno al proveedor
Control	El momento y la naturaleza de las actualizaciones están bajo tu control	El momento y los cambios en el rendimiento pueden ocurrir sin previo aviso
Personalización	Acceso completo al código fuente para personalizar el modelo según las necesidades	Capacidad limitada para personalizarlo según las necesidades
Transparencia	Inspeccionar el código y los datos ofrece mejor capacidad de auditoría y comprensión	Sin posibilidad de auditar ni entender el rendimiento
Coste	Típicamente menor coste a largo plazo debido al menor tamaño del modelo	El mayor tamaño del modelo y la propiedad premium suelen compensarse con la reducción de costes gracias a la optimización del lado del servidor
Latencia	Menor latencia gracias al alojamiento local y al menor tamaño del modelo	A menudo mayor latencia debido al mayor tamaño del modelo y a la latencia del API
Calidad	No existe un único enfoque mejor. Cada caso de uso es diferente. Los modelo propietarios suelen estar más cerca de la frontera del rendimiento	
Ejemplos	  OpenAI  Meta  deepseek   MISTRAL AI  Microsoft	 OpenAI ANTHROPIC

A large white circle is partially visible on the left edge. Below it, there is a small pink squiggle, a white diamond, a yellow diamond, a yellow circle, and a small purple dot.


Pero... es posible?



Varios modelos abiertos en el top 10

Artificial Analysis Intelligence Index

Artificial Analysis Intelligence Index v3.0 incorporates 10 evaluations: MMLU-Pro, GPQA Diamond, Humanity's Last Exam, LiveCodeBench, SciCode, AIME 2025, IFBench, AA-LCR, Terminal-Bench Hard, τ^2 -Bench Telecom




Artificial Analysis Index

Los modelos abiertos progresan!

Progress in Open Weights vs. Proprietary Intelligence

Artificial Analysis Intelligence Index v3.0 incorporates 10 evaluations: MMLU-Pro, GPQA Diamond, Humanity's Last Exam, LiveCodeBench, SciCode, AIME 2025, IFBench, AA-LCR, Terminal-Bench Hard, τ^2 -Bench Telecom

■ Open Weights ■ Proprietary





Pero... puedo usarlos?



Qué es Hugging Face?



La plataforma que los constructores de IA utilizan todo el día, cada día (HF Hub):


- Modelos, datasets, apps...
- Posts, blogs, cursos, papers, leaderboards...

2.1M

Modelos públicos

500K+

Datasets públicos



1M+

Descargas diarias

1M+

Visitantes diarios

Qué es Hugging Face? 🤗

También es un conjunto de proyectos (y muchas colaboraciones) open source para permitir el desarrollo y el avance de la IA



30+

Librerías



∞

Colaboraciones



**Pero cómo uso los
modelos abiertos?**




Cómo los uso?

- API serverless (similar a OpenAI/Anthropic): Inference Providers
- Despliegues autogestionados (despliegues en un click con infraestructura escalable): HF Endpoints 
- Despliega tú mismo (bare metal)



A large white circle is partially visible on the left edge. Below it, there are several small decorative elements: a pink squiggle, a white diamond, a yellow diamond, a yellow circle, and a small purple dot.

Cómo construyo?




Cómo construyo?

Elige modelo → Personaliza → Despliega



Encuentra el modelo



The screenshot shows the Hugging Face website's 'Models' section. The left sidebar contains navigation links for 'Main', 'Tasks', 'Libraries', 'Languages', 'Licenses', and 'Other'. Under 'Tasks', there are buttons for 'Text Generation', 'Any-to-Any', 'Image-Text-to-Text', 'Image-to-Text', 'Image-to-Image', 'Text-to-Image', 'Text-to-Video', 'Text-to-Speech', and '+42'. The 'Parameters' section features a slider from '< 1B' to '> 500B'. The 'Libraries' section lists various frameworks like PyTorch, TensorFlow, JAX, Transformers, etc. The 'Apps' section shows vLLM, TGI, llama.cpp, etc. The 'Inference Providers' section lists Nebius AI, Cerebras, etc. The main content area displays a grid of model cards. Each card includes the model name, a brief description, the number of parameters, the update date, and the number of likes. The models are sorted by 'Trending'.

Hugging Face Search models, datasets, users...

Models 2,108,369 Filter by name

Full-text search 1 Sort: Trending

Models

- openbmb/VoxCPM-0.5B**
Text-to-Speech • Updated 4 days ago • 3.24k • 614
- Alibaba-NLP/Tongyi-DeepResearch-30B-A3B**
Text Generation • 31B • Updated 6 days ago • 9.15k • 583
- ibm-granite/granite-docling-258M**
Image-Text-to-Text • 0.3B • Updated about 2 hours ago • 25.7k • 548
- Wan-AI/Wan2.2-Animate-14B**
Updated 4 days ago • 14.4k • 332
- google/vaultgemma-1b**
Text Generation • 1B • Updated 11 days ago • 3.69k • 375
- moondream/moondream3-preview**
Image-Text-to-Text • 9B • Updated about 9 hours ago • 3.23k • 229
- Qwen/Qwen3-Omni-30B-A3B-Instruct**
Any-to-Any • 35B • Updated about 20 hours ago • 1.69k • 217
- decart-ai/Lucy-Edit-Dev**
Video-to-Video • Updated 4 days ago • 1.85k • 212
- Qwen/Qwen-Image-Edit-2509**
Image-to-Image • Updated about 21 hours ago • 790 • 209
- Qwen/Qwen3-Next-80B-A3B-Instruct**
Text Generation • 81B • Updated 6 days ago • 1.02M • 717
- mistralai/Magistral-Small-2509**
24B • Updated 5 days ago • 3.43k • 169
- deepseek-ai/DeepSeek-V3.1-Terminus**
Text Generation • 685B • Updated about 8 hours ago • 1.32k • 168
- facebook/MobileLLM-R1-950M**
Text Generation • 0.9B • Updated about 2 hours ago • 4.97k • 323
- inclusionAI/Ling-flash-2.0**
Text Generation • 103B • Updated 5 days ago • 765 • 157
- tencent/SRPO**
Text-to-Image • Updated 8 days ago • 8.23k • 881
- bytedance-research/HuMo**
Image-to-Video • Updated 5 days ago • 428 • 214
- meituan-longcat/LongCat-Flash-Thinking**
Text Generation • 562B • Updated 1 day ago • 115 • 103
- XiaomiMiMo/MiMo-Audio-7B-Instruct**
8B • Updated 4 days ago • 718 • 92

<https://huggingface.co/models>

Úsalo con 🧡 Transformers

The Transformers Library: standardizing model definitions

Published May 15, 2025

[Update on GitHub](#)



TLDR: Going forward, we're aiming for Transformers to be the pivot across frameworks: if a model architecture is supported by transformers, you can expect it to be supported in the rest of the ecosystem.

Transformers was created in 2019, shortly following the release of the BERT Transformer model. Since then, we've continuously aimed to add state-of-the-art architectures, initially focused on NLP, then growing to Audio and computer vision. Today, transformers is the default library for LLMs and VLMs in the Python ecosystem.


Transformers now supports 300+ model architectures, with an average of ~3 new architectures added every week. We have aimed for these architectures to be released in a timely manner, having day-0 support for the most sought-after architectures (Llamas, Qwens, GLMs, etc.).



<https://huggingface.co/blog/transformers-model-definition>



Customízalo



TRL permite realizar post-entrenamiento de LLM/VLMs con diferentes Trainers.

```
from trl import SFTTrainer
from datasets import load_dataset

trainer = SFTTrainer(
    model="Qwen/Qwen3-0.6B",
    train_dataset=load_dataset("trl-lib/Capybara", split="train"),
)
trainer.train()
```

Despliegalo


Inference y Serving frameworks

Hugging Face Endpoints  o infraestructura propia



 VLLM



LLaMA 



SGL

Recurros

- hf.co/blog
- hf.co/learn
- [Transformers-Tutorials repo](https://github.com/NielsRogge/Transformers-Tutorials)
- [smol-vision repo](https://github.com/NielsRogge/smol-vision)



Gracias!

Sergio Paniego Blanco (@sergiopaniego)

Machine Learning Engineer @ Hugging Face

